数据分析的机器智能方法

期末课程报告

手写数字识别的 BP 与多基线比较及 PCA 降维影响分析

对照模型 逻辑回归 kNN RBF SVM

姓名 刘添屹

学号 2024141460484

课程 数据分析的机器智能方法

修订日期 2026 年 11 月 11 日

摘要

本文实现基于 NumPy 的单隐藏层 BP 网络，分析 PCA 降维对手写数字识别的影响，并与逻辑回归、kNN 和 RBF-SVM 比较。Digits 数据共 1797 例 8×8 图像，固定划分为 1257 例训练、270 例验证和 270 例测试，预处理仅在训练集拟合。原始 64 维 BP 采用 16 个 ReLU 隐藏单元，三种子测试准确率为 97.53%±0.57 个百分点；逻辑回归为 97.41%，kNN(k=1/3)为 98.15%/98.52%，RBF-SVM 为 99.26%。代表种子 0 下，BP 与逻辑回归、PCA32 与原始 64 维的精确 McNemar 检验均为 p=1.000。PCA 保留 8、16、32 维时，BP 准确率均值为 92.10%、96.79%、96.91%。简单 BP 完成了有效分类，近邻和核方法取得更高的准确率点估计；PCA 减少分类器参数，但投影状态增加了完整流程的存储开销。

关键词 手写数字识别 BP 神经网络 主成分分析 逻辑回归 近邻分类 统计检验

1 背景介绍

手写数字识别需要把书写形状转换成数字类别。同一数字可能具有不同的倾斜、粗细和连接方式，不同数字之间又可能出现局部相似，因此仅靠固定模板难以涵盖所有变化。

反向传播是计算多层网络损失函数梯度的方法。Rumelhart 等人的研究说明了误差信息怎样逐层传递到隐藏层连接，使隐藏单元能够学习任务相关的表示[1]。本文把“BP 网络”作为课程中常用的简称，具体模型为多层感知机，训练时分别由反向传播计算梯度、由梯度下降执行更新。

前期课程实验涉及 Hebb 学习和 Oja 主成分学习。本课程实验在监督分类的基础上加入线性 PCA，考察无监督降维与分类任务的关系。PCA 寻找方差较大的正交方向，以较少维数描述样本变化[2]；但方差的保留比例并不直接说明数字类别能否被区分。本文据此提出三个问题：简单 BP 网络能取得怎样的识别效果；保留不同 PCA 维数会怎样改变效果与开销；BP 与逻辑回归、近邻及核分类器相比有怎样的表现。实验设计和讨论均围绕这些问题展开。

2 国内外研究现状

2.1 梯度学习与空间表示

手写数字识别方法的差别首先在于如何利用像素之间的关系。反向传播使多层网络按分类误差学习内部表示[1]，但全连接层对每个位置分别分配权重。LeCun 等人的

卷积网络把局部连接、权值共享和下采样结合起来[3]，以较少的独立参数复用笔画特征。这种空间结构先验与单纯加宽全连接层具有不同的归纳偏置，因此网络比较还应关注特征在空间上如何组织。

整流单元和早停分别改变表示形式与优化过程。Nair 和 Hinton 在受限玻尔兹曼机中研究整流单元[4]，Prechelt 则比较验证集早停规则[5]。激活函数决定隐藏层怎样响应输入，早停决定有限预算内采用哪个参数状态；二者与网络结构共同影响结果。本实验使用确定性 ReLU 和统一早停规则，在固定条件下比较输入表示。

2017 年的胶囊网络进一步通过向量编码实体属性，以动态路由组织部分与整体关系，并在 MNIST 和重叠数字任务上评价[6]。从卷积的局部特征复用到胶囊的组合关系建模，研究重点已超出增加全连接参数。与这些空间建模方法相比，本实验的小型 MLP 不预设局部连接，近邻与核方法则依据样本相似性分类，三者形成不同表示方式的对照。

2.2 方差保留与任务评价

PCA 的目标是保留方差，监督分类关注类别分离[2]。因此，累计解释方差不能代替识别准确率；输入维数减少也不等于完整推理状态更小，因为投影矩阵仍需保存。本文同时比较分类表现、分类器参数和含预处理的参数，使统计压缩与任务收益分开评价，而不只按方差阈值选择维数。

国内研究在 MNIST 上报告 79%至 81%方差、41 至 50 维附近准确率最高[7]，本实验三个 PCA 候选的结果则随保留量增加而上升。两者的数据分辨率、候选区间和训练条件不同。本文固定 16 个隐藏单元与 300 轮上限，并结合加宽和延长预算的验证记录讨论差异，将方差保留量放回网络容量与优化条件中解释。不同数据上的最优阈值需要在各自评价协议中确定。

3 数据设计及预处理

3.1 数据来源与质量检查

数据通过 scikit-learn 的 load_digits 接口加载，包含 1797 个样本、10 个数字类别，每个样本为 8×8 灰度表示，展平后得到 64 个特征，像素取值为 0 至 16。数据源为 UCI 手写数字光学识别库，完整数据规模与本接口的 1797 例子集不同[8-9]。

检查结果显示，原始矩阵没有缺失值、无穷值或完全重复图像，标签均位于 0 至 9。各类样本量在 174 至 183 之间，类别分布较均衡，因此不进行过采样或类别加权。

训练集中约 48.85%的像素为零，反映图像背景较多；3 个恒定特征保留在 64 维输入中，避免在不同实验路径间额外改变特征选择规则。

如图 1 所示，各类训练样本呈现不同的笔画和书写形态。

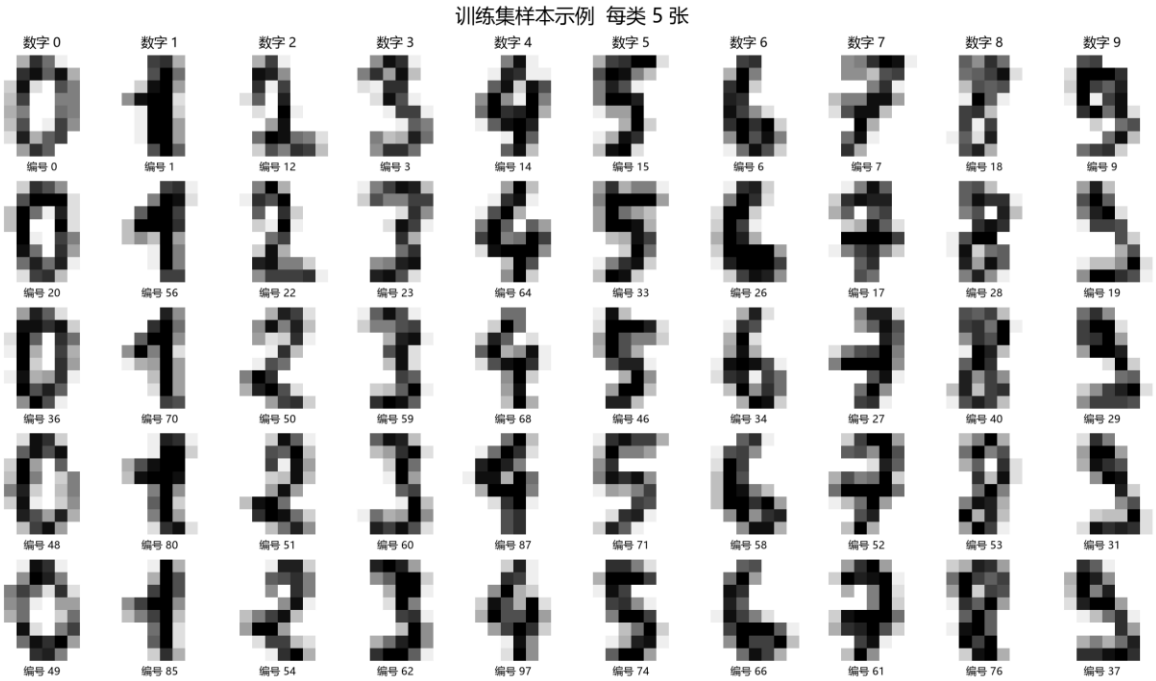


图 1 训练集手写数字样本 每类展示 5 例

3.2 固定划分与数据使用规则

首先按标签分层抽取 270 例测试样本，随机种子为 42；再从其余 1527 例中分层抽取 270 例验证样本，种子为 43，最终训练集为 1257 例。三个集合的索引交集为空，其并集覆盖全部样本。固定索引保存后，各种方法共用同一划分，避免把数据划分差异误当成模型差异。

表 1 固定数据划分及用途

子集	样本数	占全部比例	用途
训练集	1257	69.95%	拟合预处理及模型
验证集	270	15.03%	早停与参数选择
测试集	270	15.03%	冻结后的最终评价

如表 1 所示，训练集用于估计均值、PCA 方向和模型参数；验证集用于早停和开发阶段的参数选择；测试集在方案冻结后统一评价。数据先划分，再用训练集拟合预

处理，验证集与测试集仅应用相同变换。测试结果用于报告最终表现，不再反过来调整隐藏宽度、维数或学习率。

3.3 归一化与 PCA 投影

像素统一除以 16，使原始灰度映射到 0 至 1，再减去训练集均值。验证及测试样本均使用同一训练均值，不分别计算各自的均值。记原始样本为 x，训练均值为 μ，处理后的向量为 u，其表达式见式 1。

$$u = \frac{x}{16} - \mu \quad \mu = \frac{1}{n}\sum_{i=1}^{n}\frac{x_i}{16} \quad （1）$$

PCA 只在训练矩阵上通过完整奇异值分解拟合，不进行白化。设 V_k的各列为前 k 个主成分方向，则降维表示为式 2。模型接收 k 维投影，所需均值和投影矩阵必须与模型共同保存。

$$t = uV_k \quad r_k = \frac{\sum_{j=1}^{k}\lambda_j}{\sum_{j=1}^{64}\lambda_j} \quad （2）$$

训练集前 8、16、32 个主成分分别解释 67.2150%、84.9012%和 96.6796%的方差。达到 90%累计解释方差需要 21 维，达到 95%需要 28 维。本文固定比较 8、16、32 维，能够观察较强压缩、中等压缩和较高方差保留三种条件，并以原始 64 维为参照。

4 模型与算法设计

4.1 网络结构与前向传播

本文使用一个隐藏层的多层感知机，由隐藏层的非线性变换提取特征，再由输出层完成十分类。训练时使用反向传播计算梯度。输入维数 d 随实验取 64、8、16 或 32，隐藏层宽度 h 由验证集选择，输出层固定 10 个单元，对应数字 0 至 9。最终主实验采用 h=16，原始输入结构为 64→16→10。

令一个批次包含 m 个样本，输入矩阵 X 的形状为 m×d，W_1为 d×h，W_2为 h×10，偏置按样本行广播。隐藏层使用 ReLU，输出层计算类别得分 Z_2，再经 Softmax 得到概率矩阵 P。式 3 给出前向计算，式 4 给出单个样本的类别概率。

$$\begin{gathered} Z_1 = XW_1 + b_1 \quad H = \max(0, Z_1) \\ Z_2 = HW_2 + b_2 \end{gathered} \quad （3）$$

$$p_{ic} = \frac{\exp(z_{ic} - a_i)}{\sum_{j=0}^{9}\exp(z_{ij} - a_i)} \quad a_i = \max_j z_{ij} \quad （4）$$

训练损失采用批次平均交叉熵，见式 5。实际计算先减去每行最大得分，并在对数域计算 log-softmax，避免直接计算大指数或对已下溢的概率取对数。隐藏层权重采用均值 0、标准差√(2/d)的正态初始化，借鉴适合整流激活的初始化思想[10]；输出权重标准差为√(1/h)，全部偏置初始化为 0。

$$L = -\frac{1}{m}\sum_{i=1}^{m} \log p_{i,y_i} \quad (5)$$

4.2 反向传播与参数更新

令 Y 为真实标签的独热矩阵。Softmax 与交叉熵合并后，输出得分的梯度为 $G_2=(P-Y)/m$。由链式法则可得到输出层权重和偏置梯度，再将误差通过 W_2传回隐藏层，并乘以 ReLU 的导数。各梯度见式 6 至式 8，其中⊙表示逐元素乘法，$1(Z_1>0)$表示正值位置为 1 的掩码。

$$G_2 = \frac{P - Y}{m}$$
$$\nabla_{W_2} L = H^{T} G_2 \quad \nabla_{b_2} L = \sum_i G_{2,i:} \quad (6)$$

$$G_1 = (G_2 W_2^{T}) \odot 1(Z_1 > 0)$$
$$\nabla_{W_1} L = X^{T} G_1 \quad \nabla_{b_1} L = \sum_i G_{1,i:} \quad (7)$$

$$\theta \leftarrow \theta - \eta \nabla_{\theta} L \quad \theta \in \{W_1, b_1, W_2, b_2\} \quad (8)$$

所有梯度先使用同一组旧参数计算，随后统一执行参数更新。若先更新 W_2再计算隐藏层梯度，就会把不同时刻的参数混用。每轮先打乱训练索引，按 32 例组成小批量，最后不足 32 例的批次按实际样本数 m 计算平均梯度。学习率固定为 0.05，不使用动量、Dropout 或额外权重衰减。

4.3 早停与正确性验证

每轮结束后计算完整训练集和验证集的交叉熵与准确率。最大训练轮数为 300，验证损失相对上次保存值降低超过 10^{-4}时保存检查点，连续 20 轮未达到该改善阈值则停止，最后恢复保存参数。首个完成的训练轮次开始参与检查点比较。

实现采用 NumPy，核心前向传播、交叉熵、BP 梯度及更新均自行编写。两个小网络的全部 129 个参数通过中心差分检查，最大绝对误差约 3.678×10^{-10}。另从训练集中抽取每类 2 例共 20 例进行学习能力检查，准确率达到 100%，损失为 0.009047。

极端得分的数值稳定性、末尾小批次、早停恢复、短训练重复性和模型保存读取也进行了检查。

4.4 对照模型与实验配置

对照模型为多项逻辑回归，同样使用归一化和训练均值中心化后的 64 维输入，以 Softmax 形式完成十分类。逻辑回归使用 L2 正则化和 LBFGS 求解器，候选 C 为 0.1、1、10。它提供线性决策函数的参照，BP 与逻辑回归的训练配置如表 2 所示。

表 2 BP 与逻辑回归的训练配置

项目	BP 神经网络	逻辑回归
输入	原始 64 维或 PCA 8/16/32 维	原始 64 维
结构或正则化	d→16→10 ReLU Softmax	多项分类 L2 C=1
优化	小批量 SGD 学习率 0.05	LBFGS 容差 10^{-6}
训练预算	批量 32 最多 300 轮	最多 1000 次迭代
停止规则	耐心 20 轮 改善阈值 10^{-4}	求解器收敛判断
正式随机性	初始化种子 0/1/2 打乱种子加 1000	一次确定性拟合

追加基线使用相同的原始 64 维输入和固定划分。kNN 分别取 k=1 和 3，使用欧氏距离及等权投票；RBF-SVM 在验证集上从 C∈{0.1,1,10}、γ∈{scale,0.01,0.1,1}的 12 组组合选择参数，依次比较准确率、宏平均 F1 和较小 C，最终取 C=10、γ=scale。三种基线均只用 1257 例训练样本拟合。

BP 隐藏宽度候选为 16、32、64，开发种子为 42，依据验证准确率、宏平均 F1 依次选择，仍相同时优先较小宽度。三个宽度的验证准确率分别为 96.67%、96.30%、96.67%，16 维隐藏层的 F1 略高于 64 维，因此选择 h=16。逻辑回归三个 C 的验证准确率依次为 94.44%、97.04%、96.67%，选择 C=1。三种子复查中，h=32、学习率 0.05 的验证准确率均值为 96.79%，高于 h=16 的 96.67%，与开发种子 42 下的宽度排序相反，显示单种子选择存在脆弱性。该均值差对应三次验证累计仅多 1 次正确预测（783 增至 784，仍共用 270 例），参数却由 1210 增至 2410。原 h=16 已冻结并完成测试，为避免评价后回头替换正式方案，本文保留 h=16，将 h=32 留作新评价协议的候选。

正式实验中，四种输入的 BP 均使用种子 0、1、2，各进行三次训练，保持隐藏宽度和训练超参数一致。PCA 候选维数依据三次验证准确率均值选择，8、16、32 维分别为 93.09%、95.06%、96.17%，因此在降维候选中推荐 32 维。该推荐形成于查看

测试结果之前，原始 64 维作为对照继续保留。全部 18 次开发拟合完成后冻结配置，再统一评价逻辑回归及 12 个 BP 模型，共 13 个最终模型。

评价采用准确率、宏平均 F1 和混淆矩阵。准确率反映整体正确比例；宏平均 F1 先对每类计算 F1，再对 10 类等权平均，以检查总体较高准确率是否掩盖个别类别的不足。BP 报告三次均值和样本标准差，标准差分母取 n-1。这三次只改变初始化和训练打乱顺序，数据划分保持固定，故标准差反映优化随机性。

统计分析以同一测试样本上的正确与错误为配对结果，使用双侧精确 McNemar 检验。设 b 为仅前者正确的数量、c 为仅后者正确的数量，在 b+c 个分歧样本上检验成功概率为 1/2，显著性水平取 0.05。每个固定模型的准确率另计算 95% Wilson 区间；BP 按种子 0、1、2 分别检验，代表种子沿用原方案指定的 0。

5 实验及结果对比分析

5.1 训练过程与泛化差距

图 2 为预先指定的代表种子 0 下四种输入的损失曲线，图 3 展示原始输入 BP 的准确率变化。代表种子在查看测试结果前已固定，曲线不根据测试准确率挑选。各条训练损失总体下降，验证损失在后期改善趋缓，训练损失则继续降低，说明继续提高训练拟合程度不一定带来相同的验证收益。

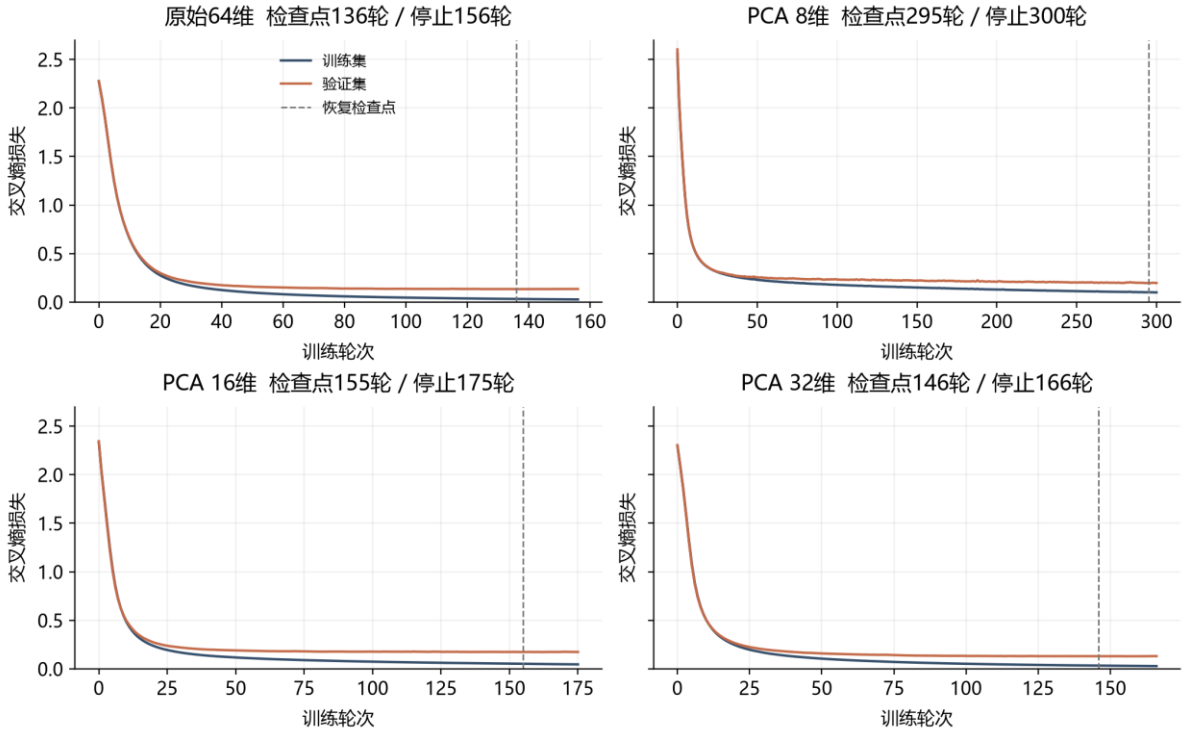


图 2 四种输入的损失曲线 种子 0 虚线为恢复检查点

原始 64 维 BP 在第 156 轮停止，恢复第 136 轮参数后，训练准确率为 99.76%，验证准确率为 96.67%，测试准确率为 97.41%。训练和验证仍相差约 3.09 个百分点。早停有助于限制无效训练。PCA8 的种子 0 训练至 300 轮上限，恢复第 295 轮；这也提示较低维数下的表现同时受表示能力与既定优化预算影响。

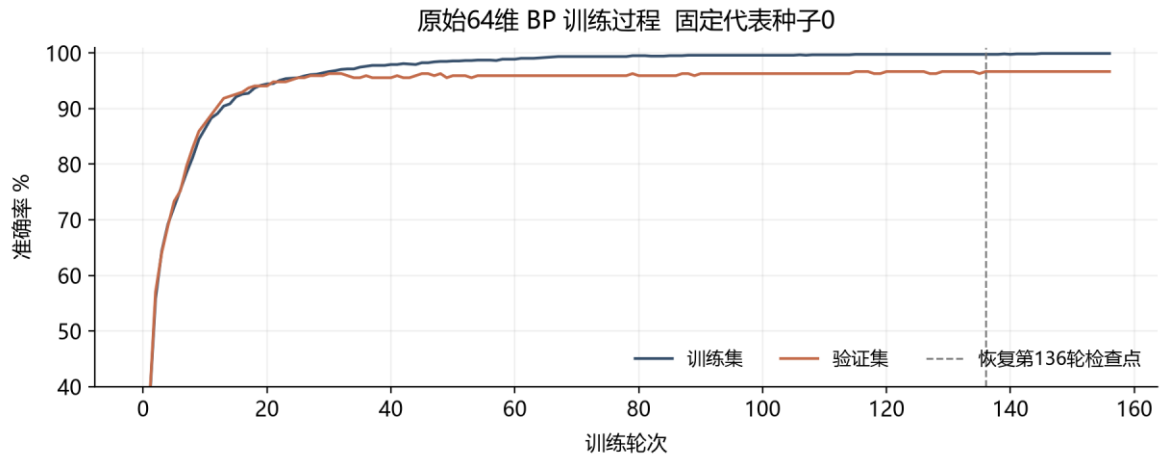


图 3 原始 64 维 BP 训练及验证准确率 种子 0

5.2 模型基线与配对统计

表 3 列出测试指标。逻辑回归准确率为 97.41%，原始 BP 三种子均值为 97.53%；kNN(k=1/3)分别正确 265/266 例，准确率为 98.15%/98.52%，RBF-SVM 正确 268 例，达到 99.26%。如图 4 所示，近邻和核方法的准确率点估计均高于原始 BP；该排序是当前测试集上的观察，不能据此断言 BP 不存在识别收益。

表 3 最终测试集识别指标

方法	维数	次数	准确率 %	宏平均 F1
逻辑回归	64	1	97.41	0.9738
kNN k=1	64	1	98.15	0.9814
kNN k=3	64	1	98.52	0.9849
RBF-SVM	64	1	99.26	0.9924
BP 原始 64 维	64	3	97.53 ± 0.57	0.9749 ± 0.0058
BP PCA 8 维	8	3	92.10 ± 1.13	0.9198 ± 0.0118
BP PCA 16 维	16	3	96.79 ± 0.86	0.9670 ± 0.0088
BP PCA 32 维	32	3	96.91 ± 0.57	0.9686 ± 0.0058

注 BP 为三种子的均值±样本标准差，标准差单位为百分点；其余模型为一次拟合。SVM 验证与测试恰好均为 268/270，两个集合索引互斥；C 与 γ 仅按验证集选择，只用 1257 例训练样本拟合，选参后未合并验证集或按测试结果改参。

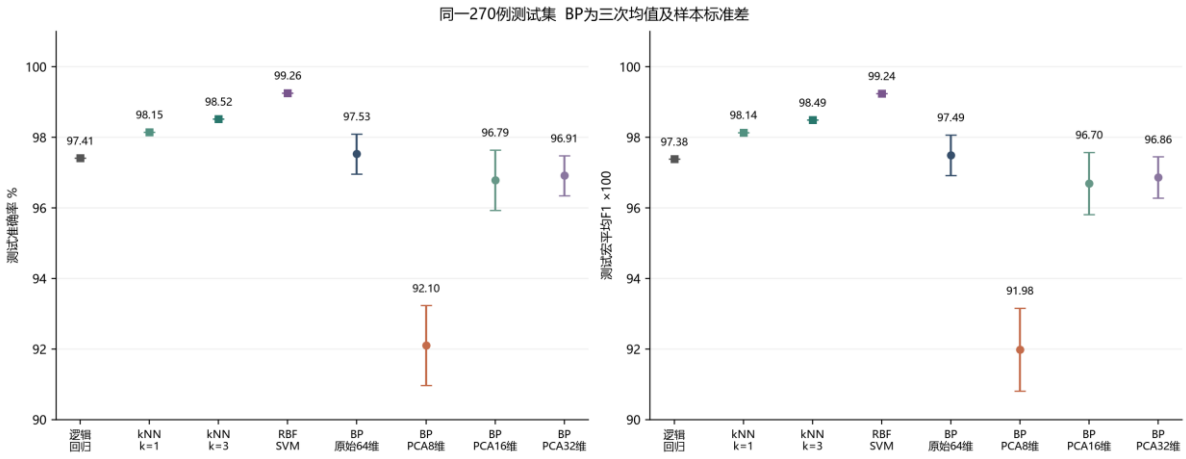


图 4 各模型测试指标 BP 误差线为三次样本标准差

代表种子 0 下，原始 BP、逻辑回归和 PCA32 均正确 263 例，准确率 97.41%的 95% Wilson 区间为[94.75%,98.74%]；kNN(k=1/3)的区间为[95.74%,99.21%]/[96.25%,99.42%]，RBF-SVM 为[97.34%,99.80%]。

如表 4 所示，BP64 对 LR 及 PCA32 对 BP64 的三个种子比较均未在 0.05 水平检出差异；新增基线对代表种子 0 的比较也列入表中。270 例测试中的分歧样本仅有 2 至 8 个，精确检验的功效受限，未检出差异不能推断模型等价，也不能作为没有收益的证据。SVM 对代表 BP 的 5:0 分歧仍对应 p=0.0625；全部分歧同向时，至少 6:0 才达到 p=0.03125，观测差为 6/270，即 2.22 个百分点。这是显著性门槛，并非 80%功效下的最小可检出差异。

表 4 各模型配对比较的精确 McNemar 检验

前者 / 后者	种子	仅前者正确	仅后者正确	双侧 p 值
BP64 / LR	0	1	1	1.0000
BP64 / LR	1	3	1	0.6250
BP64 / LR	2	2	3	1.0000
PCA32 / BP64	0	2	2	1.0000
PCA32 / BP64	1	1	6	0.1250
PCA32 / BP64	2	4	4	1.0000
kNN1 / BP64	0	4	2	0.6875
kNN3 / BP64	0	5	2	0.4531
RBF-SVM / BP64	0	5	0	0.0625

注 前者与后者仅按是否分类正确形成配对。BP 对 LR 和 PCA32 对 BP64 列出三个种子；新增基线沿用预先指定的种子 0 作为主比较。

从数据条件看，8×8 图像位于统一像素网格，欧氏距离近邻相当于在 1257 个训练样本中检索相似笔画模板，无需估计全局网络的 1210 个参数。一种解释是，这种局部相似性适合当前小样本任务，而全连接 MLP 还需从有限数据同时学习表示和分类边界。LeCun 等人的局部连接与权值共享提供了另一种利用空间结构的方式[3]；它与简单加宽网络不同。当前排名与这一解释相符，但是否由样本量或结构先验造成，仍需学习曲线及空间扰动对照验证，不能直接认定 CNN 必然胜出。

5.3 PCA 维数对分类效果的影响

PCA8 把输入从 64 维减到 8 维，维数减少 87.5%，但仅保留 67.22%的训练方差，测试准确率均值降至 92.10%。增加到 16 维后，保留方差为 84.90%，准确率升至 96.79%；32 维保留 96.68%的方差，准确率为 96.91%。图 5 显示，在本次候选范围内，提高保留维数与分类表现改善同时出现。

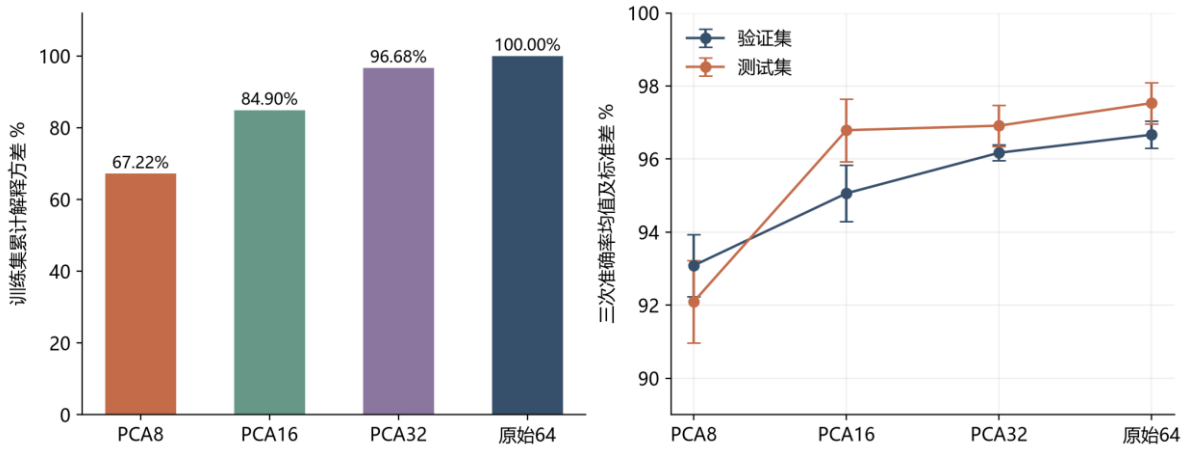


图 5 训练集方差保留比例与验证及测试准确率

PCA32 使输入维数减半，三次测试准确率均值仍比原始输入低约 0.62 个百分点。若目标是优先保持当前协议下的识别效果，原始输入提供了较好的参照；若后续系统存在输入维数约束，可以把 PCA32 作为保留较多方差的候选，但应同时考察额外投影的代价。

文献[7]的最佳方差区间为 79%至 81%，本实验比较的 67.22%、84.90%、96.68%三个保留量则呈逐项升高。本文固定隐藏层 16 单元及最多 300 轮；复查将 PCA8 预算扩至 600 轮后，验证均值从 93.09%变为 93.21%。这些结果把 PCA 保留量、网络容量和优化预算联系起来，后续可在共同的方差网格上联合比较三者。

5.4 参数量与训练开销

BP 可训练参数量为 dh+h+10h+10。h=16 时，原始 64 维网络有 1210 个参数，PCA8、16、32 网络分别有 314、442、698 个参数。如表 5 所示，PCA32 使分类器参数减少 42.31%，但推理还需保存 64 个均值及 32×64 个投影系数，完整流程合计 2810 个浮点参数，超过原始流程的 1274 个。因此，讨论存储开销时必须区分分类器与整个处理流程。

表 5 分类器参数与完整流程开销

方法	分类器参数	含预处理参数	流程耗时 秒
逻辑回归	650	714	0.030
BP 原始 64 维	1210	1274	1.526 ± 0.190
BP PCA 8 维	314	890	2.042 ± 0.334

方法	分类器参数	含预处理参数	流程耗时 秒
BP PCA 16 维	442	1530	1.247 ± 0.427
BP PCA 32 维	698	2810	1.719 ± 0.224

注 参数量统计预测所需的浮点均值、PCA 投影及分类器系数，不计文件元数据。流程耗时为预处理拟合与训练验证变换，加模型初始化和训练；BP 含逐轮验证、早停判断及检查点恢复，不含数据读写、绘图、保存和测试。

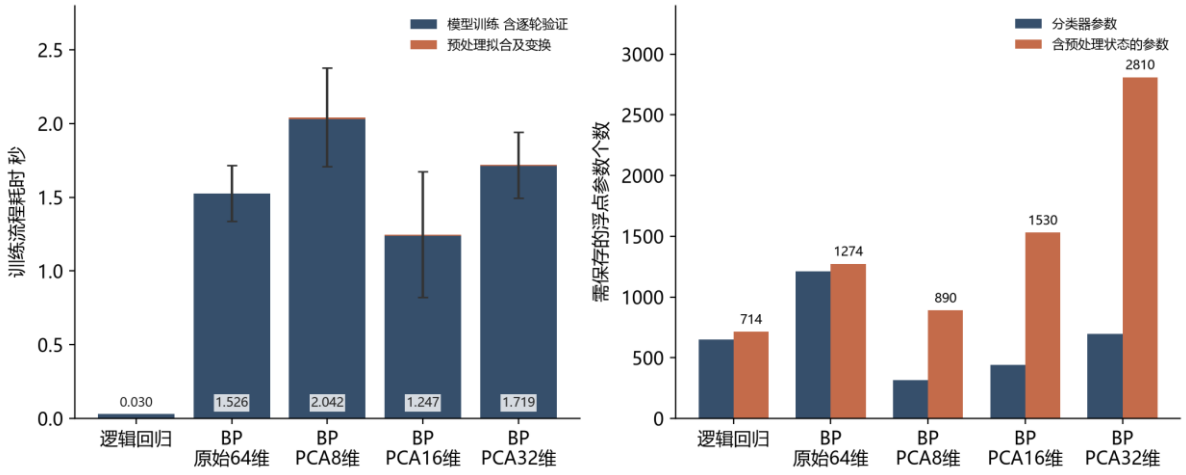


图 6 实测流程耗时与两种参数量口径

如图 6 所示，原始 BP 的平均流程耗时约 1.526 秒；PCA8、16、32 分别为 2.042、1.247、1.719 秒。PCA16 在本机上平均耗时较少，但标准差为 0.427 秒；PCA8 与 PCA32 均未比原始输入更快。实际耗时还受停止轮次、批次计算和预处理影响。逻辑回归约 0.030 秒，其库实现和 LBFGS 优化与手工 BP 的小批量 SGD 不同。

实验在同一 Windows 电脑上顺序运行，数值线程数限制为 1，使用 Python 3.12.14、NumPy 2.5.4、SciPy 1.18.1、scikit-learn 1.9.1。不同输入的 BP 均在相同训练规则下运行，但不是固定轮数计时。

5.5 混淆矩阵与误分类样本

固定种子 0 的原始 BP 和 PCA32 均正确 263 例，错误数相同，但错误构成不同。原始 BP 将 2 例数字 1 判为 8、2 例数字 8 判为 1，另有 6→1、8→7、9→4 各 1 例；PCA32 有 8→1 共 2 例，其余为 1→0、1→5、1→9、6→1、9→8 各 1 例。图 7 使用行表示真实标签、列表示预测标签，矩阵中的数值为样本数。

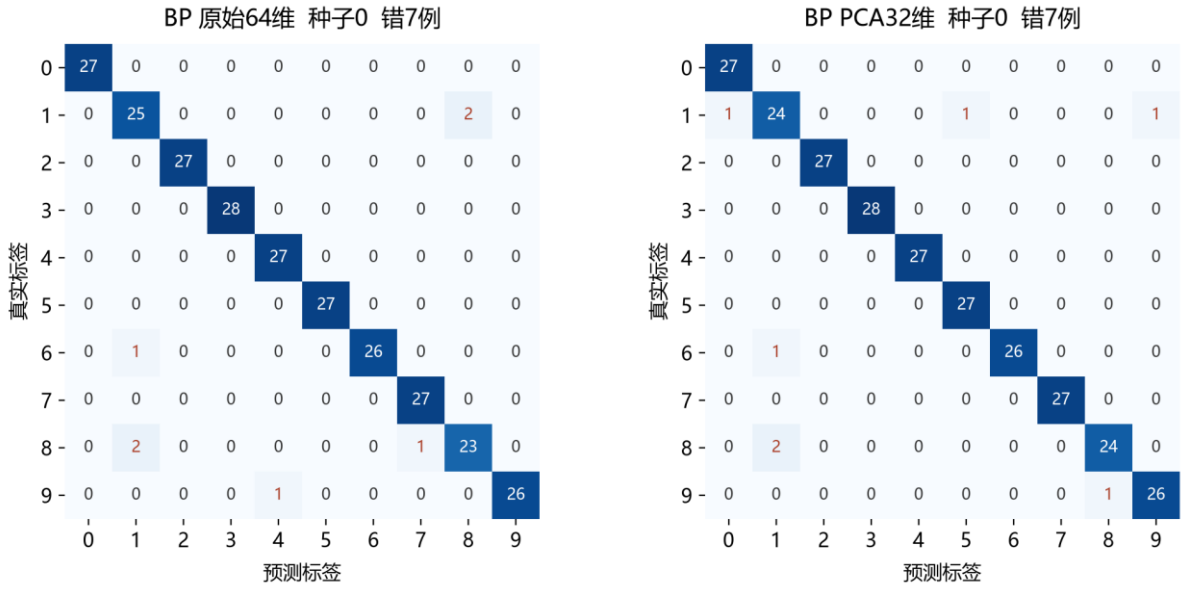


图 7 原始 BP 与 PCA32 的混淆矩阵 种子 0 每图 270 例

原始 BP 中数字 8 的召回率为 23/26，约 88.46%；PCA32 中数字 1 的召回率为 24/27，约 88.89%。尽管整体准确率相同，类别层面的薄弱点仍有变化。逻辑回归同样错 7 例，主要包含 8→1 和 9→4 各 2 例，说明当前测试样本中确有多种模型都难以处理的情况。

图 8 分别把两种 BP 的全部错误按原始数据索引升序排列，展示前 6 例，完整错误清单均保留。共同错误中部分预测标签也发生改变，说明只看错误总数不足以理解表示变化的影响。

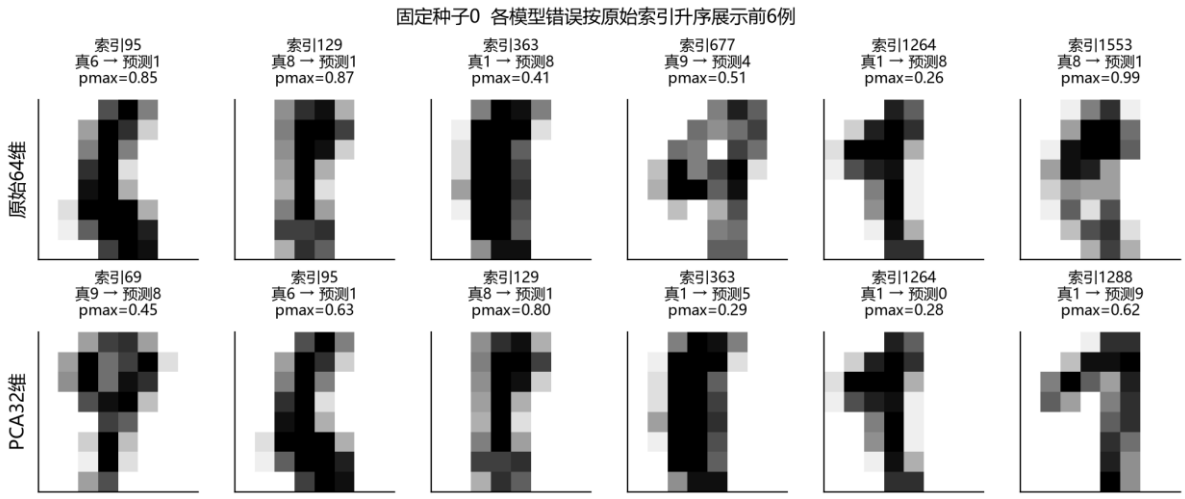


图 8 各模型按原始索引排序的前 6 个错误 上原始 BP 下 PCA32

例如，索引 95 的真实标签为 6，低分辨率显示中笔画较集中且形状细长，两种模型均预测为 1；索引 129 和 1553 真实为 8，同样被预测为 1。索引 1553 在原始 BP 上的最大 Softmax 概率约 0.985，却仍然错误。

5.6 检验功效与局限性

最小可检出差异（MDE）需指定显著性水平、目标功效和总体分歧率 q。取双侧 $\alpha=0.05$、功效 80%，在独立样本对及 $q=8/270$ 的敏感性情景下，枚举分歧数 $M\sim Bin(270,q)$，再对 $B|M\sim Bin(M,(1+\Delta/q)/2)$的精确拒绝域求和，得到 MDE 约 2.94 个百分点，Δ 为真实准确率差。若 $q\leq 7/270$，即使全部分歧同向，功效上限也不超过 70.3%，达不到 80%目标。这些是给定分歧率的设计敏感性结果，不能当作真实效应的估计。

本实验只有一次固定划分，三种子共用 270 例测试集，不能当作 810 个独立样本，也未按书写者分组。新增基线是原测试成绩已报告后的追加分析。SVM 对种子 2 的探索性 $p=0.03125$，对种子 0 和 1 则为 0.0625 和 0.25，且未校正多重比较，因此不凭单个小 p 值宣称稳定优势。容量、样本量及训练预算的归因还需要共同协议下的控制实验。

6 总结及讨论

本文完成了 Digits 预处理、NumPy BP 实现、PCA 对照和四类分类方法比较。梯度差分及小样本学习验证了实现，原始 BP 三种子准确率均值为 97.53%，与逻辑回归 97.41%接近；精确 McNemar 检验在三个种子下均未检出两者差异。kNN(k=1/3)与 RBF-SVM 分别取得 98.15%/98.52%和 99.26%的点估计，这些点估计高于当前小型 BP，但在分歧样本稀少、检验功效有限的条件下，现有证据不足以确认稳定优劣，也不支持模型等价或非线性表示无收益的结论。

关于降维，PCA8 显著减少输入维数，但伴随较大的准确率下降；PCA16 和 PCA32 保留了更多方差，分类效果接近原始输入，仍未超过原始 BP 的测试均值。PCA32 由验证集推荐，适合用于说明较高方差保留条件下的结果，但并未同时改善所有成本指标。其分类器较小，而加上投影后的总参数更多，平均训练流程时间也较长。评价一种预处理方法，需要同时明确准确率、参数统计对象和计时范围。

后续若扩展实验，可先在新的训练验证协议中比较多个划分，并按实际应用条件考虑书写者分组，再重新冻结参数后评价独立测试集。也可在同一预算下研究学习率与降维维数的交互，或进行输出概率校准。通过本次课程实验，可以把监督误差学习、主成分提取与实验评价联系起来，并理解较高方差保留、较小网络和较高分类准确率分别回答不同的问题。

7 参考文献

[1] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning representations by back-propagating errors[J]. Nature, 1986, 323: 533-536. DOI: 10.1038/323533a0.

[2] JOLLIFFE I T, CADIMA J. Principal component analysis: a review and recent developments[J]. Philosophical Transactions of the Royal Society A, 2016, 374(2065): 20150202. DOI: 10.1098/rsta.2015.0202.

[3] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324. DOI: 10.1109/5.726791.

[4] NAIR V, HINTON G E. Rectified Linear Units Improve Restricted Boltzmann Machines[C]//Proceedings of the 27th International Conference on Machine Learning. 2010: 807-814.

[5] PRECHELT L. Early Stopping - But When?[M]//ORR G B, MÜLLER K R, eds. Neural Networks: Tricks of the Trade. Berlin: Springer, 1998: 55-69. DOI: 10.1007/3-540-49430-8_3.

[6] SABOUR S, FROSST N, HINTON G E. Dynamic Routing Between Capsules[C]//Advances in Neural Information Processing Systems. 2017, 30: 3856-3866.

[7] 张婧, 刘倩. 主成分分析阈值选择差异性分析研究[J]. 数据采集与处理, 2022, 37(5): 1012-1017. DOI: 10.16337/j.1004-9037.2022.05.006.

[8] ALPAYDIN E, KAYNAK C. Optical Recognition of Handwritten Digits[DS/OL]. UCI Machine Learning Repository, 1998[2026-11-11]. DOI: 10.24432/C50P49.

[9] Scikit-learn developers. load_digits[EB/OL]. [2026-11-11]. https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_digits.html.

[10] HE K, ZHANG X, REN S, et al. Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification[C]//Proceedings of the IEEE International Conference on Computer Vision. 2015: 1026-1034. DOI: 10.1109/ICCV.2015.123.